

社交推荐的解纠缠对比学习

摘要

传统的社交推荐模型通常将用户的表示分为协作领域（用户-物品交互）和社会领域（社会关系），但这种方法可能无法捕捉用户在这两个领域中的异构行为模式，从而降低了用户表示的表达性。因此作者提出了一种新的社会推荐框架，称为非纠缠对比学习框架（DcRec）[1]。该框架的核心思想是从协作和社会领域学习未纠缠的用户表示，以提高用户行为模式的建模效果。DcRec 使用非纠缠对比学习框架，旨在实现解纠缠的用户表示之间的知识转移，以更好地进行社会推荐。这种方法的优势在于可以更全面地捕捉用户在协作和社会领域中的行为特征。通过在各种真实数据集上进行综合实验证明，证实了 DcRec 模型相较于传统方法的优越性。

关键词：社交推荐；非纠缠对比学习；协作领域；社会领域；

1 引言

根据社会关联理论，研究者们致力于提高在线平台（如 Facebook、微信、LinkedIn 等）的推荐性能，通过考虑用户与周围社交好友的关系对物品偏好的影响，这一研究方向被称为社交推荐。

在社交推荐中，用户与物品和社交好友进行交互，涉及到协作领域和社会领域，每个领域有不同的目的[2]。然而，现有的用户偏好建模方法采用统一的用户表示，无法充分考虑用户在协作和社交领域中的异质行为模式。例如，一些模型利用节点级注意力层将来自社会 and 协作领域的用户表示融合，但这种方法不能很好地模拟用户在不同领域中的差异行为。

为了解决这一问题，本研究提出将用户行为分解为协作领域和社会领域，以更好地学习用户在社交推荐任务中的分解表示。挑战在于如何在两个领域中学习这些分离的用户表示，并在社会领域和协作领域之间传递知识。最近，自监督学习（SSL）作为一种新兴学习方法，通过最大化同一实例的不同增强视图之间的互信息，从未标记的数据中获取自我监督信号[3]，已被证明在各种领域任务中非常有效。

在这个研究中，引入了领域分解的思想，将用户行为分解为协作和社会领域。此外，采用基于对比学习的框架来解决这一问题。具体而言，提出了解纠缠的对比学习目标，通过最大化解纠缠表示之间的互信息，实现了知识从社会领域向协

作领域的转移。相较于一些模型的隐式解纠缠方法，该研究明确了来自不同域的数据的解纠缠，并基于独立的邻接矩阵传播节点表示。

2 相关工作

社交网络分析是一种研究人际关系、组织结构和信息流动等社交系统的方法。这种分析方法主要关注于节点（个体或组织）之间的关系以及这些关系的网络结构。社交网络可以是实际的人际关系网络，也可以是其他形式的关系网络，如互联网上的网络、合作关系网络等，因此在许多领域中都有应用，包括社会学、心理学、管理学、信息科学等。研究者可以利用社交网络分析来揭示社会结构、发现关键节点、理解信息传播模式，甚至在推荐系统和营销策略中应用这些知识。图神经网络（Graph Neural Network，简称 GNN）是一类专门用于处理图结构数据的神经网络模型[4]。与传统的神经网络主要处理向量或矩阵数据不同，图神经网络可以有效地捕捉和学习图数据中的复杂关系和结构。由于它能够有效地捕捉和利用图结构中的信息，提高推荐的精度和个性化，图神经网络在社交网络推荐中得到广泛应用。

2.1 LightGCN

GCN 的核心思想是通过迭代的图卷积操作，利用节点及其邻居的信息来学习节点在图结构中的表示[5]。AGG 函数是图卷积的关键部分，负责聚合邻居节点的特征。在不同的 GCN 变体中，AGG 函数的具体形式有所不同，涉及特征转换和非线性激活等操作。虽然这些操作在节点分类等任务中表现出色，但对于协同过滤任务可能显得过于繁琐，需要更轻量级的模型。在选择适当的模型结构和 AGG 函数时，需考虑任务需求和数据特性。在 LightGCN 中，采用简单的加权和聚合器，放弃了特征变换和非线性激活的使用[6]。

LightGCN 中的图卷积操作定义为：

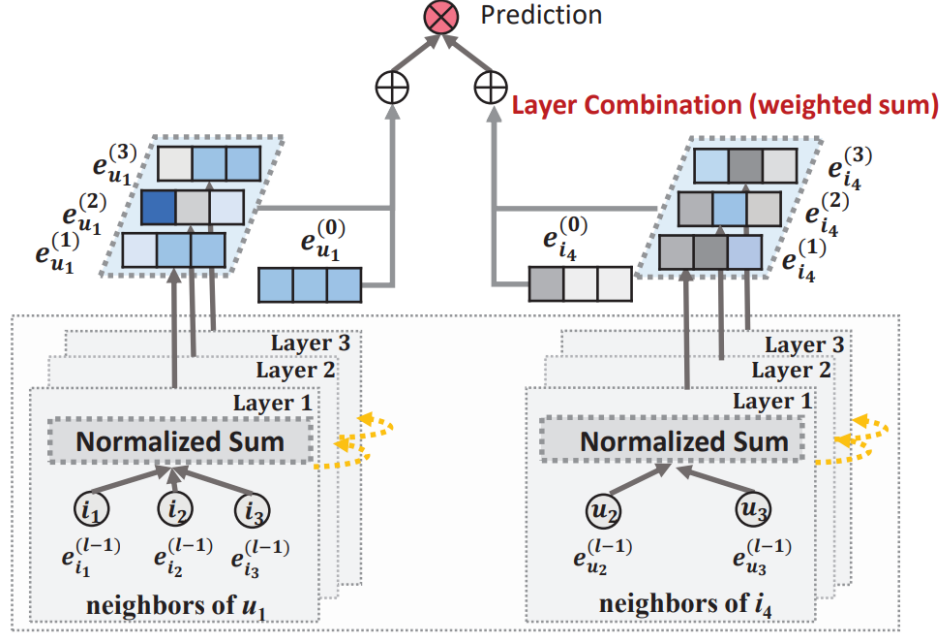
$$\mathbf{e}_u^{(k+1)} = \sum_{i \in N_u} \frac{1}{\sqrt{|N_u|}\sqrt{|N_i|}} \mathbf{e}_i^{(k)}, \mathbf{e}_i^{(k+1)} = \sum_{u \in N_i} \frac{1}{\sqrt{|N_u|}\sqrt{|N_i|}} \mathbf{e}_u^{(k)}.$$

在图卷积网络（GCN）的设计中，对称归一化项 $\frac{1}{\sqrt{|N_u|}\sqrt{|N_i|}}$ 是一种常见选择是

防止嵌入规模随图卷积操作次数的增加而增长。与此相比，L1 范数是另一种可能的正则化选择，有助于学习更紧凑、有区分性的特征表示。在 LGC 中，与标

准图卷积操作的不同之处在于它仅聚合连接的邻居，而不包括目标节点自身的连接。这种选择有助于在任务需要时排除自连接，以适应特定的数据结构和任务背景。

整个算法流程图如下所示：



在 LightGCN 中，唯一可训练的模型参数是第 0 层的嵌入，即所有用户的 $e_u^{(0)}$ 和所有项目的 $e_i^{(0)}$ 。当它们给定时，可以通过定义的 LGC 计算更高层的嵌入。在 K 层 LGC 之后，进一步将每层得到的嵌入组合起来，形成最终的表示：

$$e_u = \sum_{k=0}^K a_k e_u^{(k)}; e_i = \sum_{k=0}^K a_k e_i^{(k)},$$

模型预测定义为用户与物品最终表示的内积：

$$y_{ui} = e_u^T e_i,$$

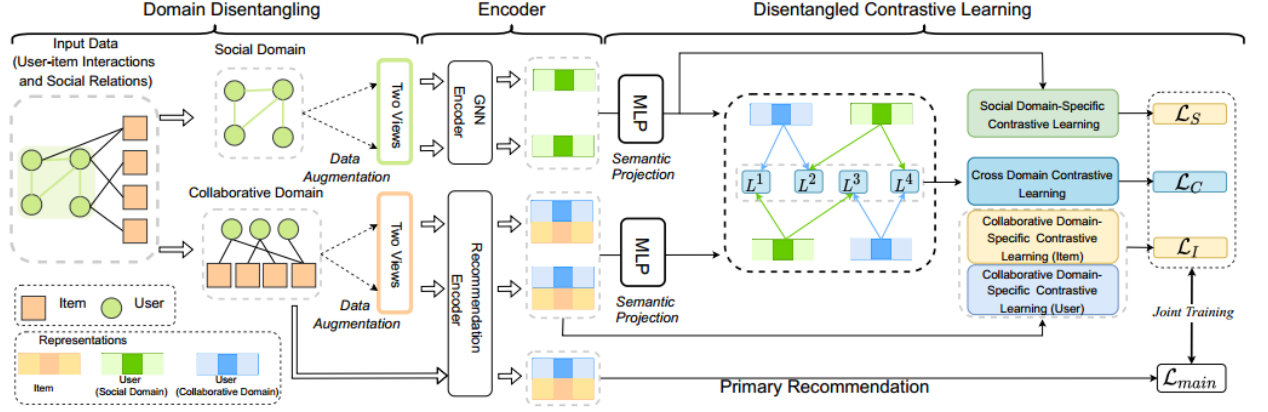
y_{ui} 值被用作推荐生成的排名分数。

3 本文方法

3.1 框架概述

用于社交推荐的 Disentangled 对比学习框架 (DcRec)，该框架遵循自监督对比学习的一般范式，通过最大化同一实例上不同观点之间的表征一致性。更具体地说，所提出的体系结构包括三个主要组成部分：(1) 域解开，将输入数据

分解为两个子域; (2) 编码器, 在两个域中使用不同的编码器来学习来自两个不同视图的表示; (3) 解纠缠对比学习, 通过对解纠缠对比学习任务 and 主推荐任务进行联合优化, 将社会领域的知识转移到推荐建模任务中。整体流程图如下所示:



3.2 域解开

为了减轻社会领域和协作领域语义差异带来的影响, 将输入数据分解为两个领域, 分别用协作领域的用户-物品交互矩阵 A_I 和社会领域的社会关系矩阵 A_S 表示[7]。在域解纠缠之后, 执行数据扩充, 以获得每个域中数据的不同视图。由于社交推荐中的数据可以自然地表示为图, 因此可以通过基于图的数据增强方法对输入(即用户-项目交互)进行增强, 其公式如下:

$$A_S^{(1)} = H_S^{(1)}(A_S), A_S^{(2)} = H_S^{(2)}(A_S),$$

$$A_I^{(1)} = H_I^{(1)}(A_I), A_I^{(2)} = H_I^{(2)}(A_I),$$

其中 $H_S^{(*)}$ 和 $H_I^{(*)}$ 分别表示在社会领域和协作领域生成两个视图的独立增强函数。

3.3 编码器

为了对用户-物品交互和社会关系建模, 利用编码器来学习每个领域中用户和项目的表示。此外, 为了确保语义一致性, 在对来自两个不同领域的用户表示进行跨领域对比学习时, 还将用户表示投影到相同的语义空间中。这里, 使用分别用 $Rec(\cdot)$ 和 $F(\cdot)$ 表示协同域和社会域的编码器。任何基于协同过滤的模型(例如 MF、NeuMF 和 LightGCN)都可以设置为协同域中的推荐编码器

$Rec(\cdot)$ ，可以设置图神经网络(gnn)方法作为社交编码器 $F(\cdot)$ 。

3.4 解纠缠对比学习

解纠缠对比学习包括跨领域的对比学习和特定领域的对比学习。通过设计跨领域的对比学习，将知识从社会领域转移到协作领域。为了在对比学习范式下利用来自未标记数据的自我监督信号，引入了特定于领域的损失，以最大限度地提高每个领域中同一实例的不同观点之间的表示一致性。

3.5 模型优化

主推荐任务：通过计算用户 u 和物品 i 之间的内积，可以预测用户与物品之间的交互可能性得分。为了优化这个任务，采用了贝叶斯个性化排序（BPR）损失函数[8]。

$$\mathcal{L}_{main} = \sum_{(u,i,j) \in \mathcal{O}} -\log \sigma(y_{ui} - y_{uj}),$$

这里的 $\mathcal{O} = \{(u, i, j) \mid (u, i) \in \mathcal{O}^+, (u, j) \in \mathcal{O}^-\}$ 。 \mathcal{O}^+ 是观测到的相互作用的集合， \mathcal{O}^- 是未观测到的相互作用的集合。

联合训练：采用了联合训练策略来优化整个模型。这些联合的损失函数包括主要推荐任务的损失、协同领域和社交领域的对比学习损失、解耦对比学习损失以及正则化项。通过联合训练可以同时优化推荐性能和对比学习的效果。联合训练损失函数为

$$\mathcal{L} = \mathcal{L}_{main} + \lambda_1(\mathcal{L}_I + \mathcal{L}_S) + \lambda_2 \mathcal{L}_C + \lambda_3 \|\xi\|_2,$$

这其中 λ_1 、 λ_2 和 λ_3 是平衡各种对比学习损失和正则化项的贡献。

4 复现细节

4.1 实验数据集

采用两个真实数据集上进行了实验：Dianping 和 Ciao。对于每个数据集，将交互划分为训练集、验证集和测试集的比例为 8:1:1。

Dataset	#Users	#Items	#Ratings	#Relations	Density
Dianping	16,396	14,546	51,946	95,010	0.022%
Ciao	7,375	105,114	284,086	111,781	0.037%

4.2 评估指标

使用了 3 个广泛使用的指标来评估模型的 top-N 排名推荐性能: Precision, Recall 和 Normalized Discounted Cumulative Gain (NDCG) [9], top-N 就是与用户交互分数的前 N 项目排名, 在这里 N 分别采用了 5, 10, 20。

$$\text{Precision} = \frac{tp}{tp + fp}$$
$$\text{Recall} = \frac{tp}{tp + fn}$$

其中 tp, fp, fn 表示真阳性、假阳性和假阴性推荐项目的数量。其中真阳性和假阳性推荐项目是交互推荐的结果。假阴性推荐项目是非互动推荐的结果。

$$\text{NDCG@N} = \frac{r(1) + \sum_{i=2}^k \frac{r(i)}{\log_2^i}}{\sum_{i=1}^{|REL|} \frac{r(i)}{\log_2^{i+1}}}$$


其中 r(i) 为相关性评分。r(i)=1 表示推荐项目与用户有交互。r(i)=0 表示没有交互。|REL| 表示按相关分数降序排序的 top-n 推荐项目的总和。

4.3 创新点

将用于协作领域的推荐编码器从 LightGCN 换成 SocialLGN, SocialLGN 是对 LightGCN 改进的一种算法。跟 LightGCN 相比, SocialLgn 考虑到了用户与用户之间的社会关系, 这社会关系提供有关用户潜在兴趣的信息, 因此若二者分别单独用于社交推荐的话, SocialLGN 会有更好的性能 [10]。

5 实验结果与分析

考虑到每次迭代要花一定的时间, 只迭代了 200 次, 模型的 loss 值随迭代次数的变化 (Dianping) 如下所示:



可以看到当迭代次数到 100 时，loss 值的变化也逐渐趋于平缓

实验结果：

Dataset	Metric	DcRec (LightGCN)	DcRec (SocialLGN)
Dianping	Precision@10	0.02654	0.02582
	Precision@20	0.02128	0.02096
	Recall@10	0.07085	0.06883
	Recall@20	0.11278	0.11114
	NDCG@10	0.05311	0.05191
	NDCG@20	0.06766	0.06655
Ciao	Precision@10	0.02091	0.02200
	Precision@20	0.01539	0.01635
	Recall@10	0.03404	0.03687
	Recall@20	0.04937	0.05295
	NDCG@10	0.03477	0.03708
	NDCG@20	0.03836	0.04077

分析：

从结果上看引用了 SocialLGN 作为编码器，在 Dianping 的数据集总体上要比编码器为 LightGCN 差点，但是在 Ciao 的数据集上 SocialLGN 相比 LightGCN 还是有一定的提升。Ciao 数据集要比 Dianping 数据集更密集，这就可能对于 SocialLGN 相比于 LightGCN 来说能更多地挖掘到社会关系的隐藏信息。

6 总结与展望

为了模拟用户在社会领域和协作领域的异质行为模式,作者提出了一种解纠缠的社会推荐对比学习框架,该框架将两个领域解纠缠并分别学习用户在每个领域的表征。此外,还设计了跨领域的对比学习,将知识从社会领域转移到协作领域,从而提高推荐性能。

在复现工作中,将协作领域的推荐编码器由 LightGCN 改为 SocialLGN,在 ciao 的数据集上有一定的提升,但是在 Dianping 数据集上没有提升,以后将会对整个模型的创新作更深入的研究。

参考文献

- [1] Wu J, Fan W, Chen J, et al. Disentangled contrastive learning for social recommendation[C]//Proceedings of the 31st ACM International Conference on Information & Knowledge Management. 2022: 4570-4574.
- [2] Wenqi Fan, Tyler Derr, Yao Ma, Jianping Wang, Jiliang Tang, and Qing Li. 2019. Deep adversarial social recommendation. In Proceedings of the 28th International Joint Conference on Artificial Intelligence. China.
- [3] Ting Chen, Simon Kornblith, Mohammad Norouzi, and Geoffrey E. Hinton. 2020. A simple framework for contrastive learning of visual representations. In Proceedings of the 37th International Conference on Machine Learning.
- [4] Scarselli F, Gori M, Tsoi A C, et al. The graph neural network model[J]. IEEE transactions on neural networks, 2008, 20(1): 61-80.
- [5] Zhang S, Tong H, Xu J, et al. Graph convolutional networks: a comprehensive review[J]. Computational Social Networks, 2019, 6(1): 1-23.
- [6] He X, Deng K, Wang X, et al. Lightgcn: Simplifying and powering graph convolution network for recommendation[C]//Proceedings of the 43rd International ACM SIGIR conference on research and development in Information Retrieval. 2020: 639-648.
- [7] You Y, Chen T, Sui Y, et al. Graph contrastive learning with augmentations[J]. Advances in neural information processing systems, 2020, 33: 5812-5823.
- [8] Rendle S, Freudenthaler C, Gantner Z, et al. BPR: Bayesian personalized ranking

from implicit feedback[J]. arXiv preprint arXiv:1205.2618, 2012.

- [9] Wang Y, Wang L, Li Y, et al. A theoretical analysis of NDCG type ranking measures[C]//Conference on learning theory. PMLR, 2013: 25-54.
- [10] Liao J, Zhou W, Luo F, et al. SocialLGN: Light graph convolution network for social recommendation[J]. Information Sciences, 2022, 589: 595-607.